

Prueba 5 - Ensamblado por stacking (meta-modelo)

Este notebook parte de la Prueba 4 (ensamblado por media) y prueba una alternativa: en vez de promediar a mano las predicciones de los modelos base, se entrena un **meta-modelo** que aprende, a partir de los valores reales, como combinar mejor las salidas de los modelos base.

Pasos:

1. Carga los mismos modelos base que la Prueba 4 (single-target + familias multisalida, cada una como ensamblado interno de varios miembros).
2. Ejecuta el smoke test habitual sobre todo `eval.csv`.
3. Separa `eval.csv` en dos bloques: uno para **entrenar el meta-modelo** (meta-train) y otro para **evaluarlo** (meta-test / holdout), para no medir el meta-modelo con los mismos datos con los que se ha entrenado.
4. Para cada target, entrena un meta-modelo (Ridge) que recibe como entrada las predicciones de los modelos base y como salida el valor real.
5. Repite el smoke test sobre el meta-modelo, esta vez sobre el holdout.
6. Compara el error del meta-modelo frente a cada modelo base y frente al ensamblado simple por media (Prueba 4), todo medido sobre el mismo holdout.

1.- Configuración y carga de librerías

Misma configuración que la Prueba 4, pero en este caso se añaden las siguientes variables los meta-modelos:

- `META_TEST_SIZE` : proporcion de filas de `eval.csv` que se reservan como holdout para evaluar los meta-modelos (el resto se usa para entrenarlos).
- `META_MODEL_FACTORIES` : diccionario `{nombre: funcion_que_crea_el_modelo}`, con varios meta-modelos candidatos a probar en paralelo (Ridge, Lasso, ElasticNet, regresion lineal sin regularizar, y un Random Forest como candidato no lineal). Todos se entrenan y evaluan igual, y se comparan al final en la misma tabla. Se puede anadir o quitar candidatos libremente.

Nota: Si el tamaño general del dataset es bajo, hacer uso solamente de los datos de eval.csv. Los resultados de esta prueba de deben de tomar un uno o varios granos de sal, para tener datos realmente verídicos se recomendaría realizar una sub-prueba aún más grande. Si se obtienen más datos lo recomendable sería recurrir a CV (Validación Cruzada) o a hacer uso de un valor para el hold-out aún más grande.

```
In [1]: import json
import warnings
from pathlib import Path

import joblib
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.ensemble import RandomForestRegressor
from sklearn.linear_model import ElasticNet, Lasso, LinearRegression, Ridge
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
from sklearn.model_selection import train_test_split

warnings.filterwarnings("ignore")
sns.set_theme(style="whitegrid")
RANDOM_STATE = 42
np.random.seed(RANDOM_STATE)

print("Librerias cargadas correctamente...")

MODELS_DIR = Path("output/models")
EVAL_PATH = Path("input/eval.csv")

TARGETS_ORDER = [
    # Shannon
    'nematode_shannon_z',
    'macro_shannon_z',
    'earthworm_shannon_z',
    'orib_shannon_z',
    'meso_shannon_z',
    'coll_shannon_z',
    'bac_shannon_z',
    'fun_shannon_z',
    'euk_shannon_z',
    'oomy_shannon_z',
    'cerc_shannon_z',
    # Richness
    'macro_order_richness_z',
    'earthworm_richness_z',
    'orib_species_richness_z',
    'meso_species_richness_z',
    'coll_species_richness_z',
    'bac_asv_richness_z',
    'fun_asv_richness_z',
    'euk_asv_richness_z',
    'oomy_asv_richness_z',
    'cerc_asv_richness_z'
]

FEATURES_AUTORIZADAS = [
    'total_plant_cover_z',
    'clay_content_z',
    'silt_content_z',
    'sand_content_z',
    'aggregate_stability_z',
    'bulk_density_z',
    'soil_moisture_z',
    'as_z',
    'cu_z',
    'k_z',
    'mo_z',
    'ni_z',
    'p_z',
```

```

'pb_z',
'zn_z',
'soil_ph_z',
'plot_total_organic_c_z',
'plot_total_n_z',
'gee_temp_media_C_z',
'gee_humedad_rel_pct_z',
'gee_ndvi_verano_z',
'dem_elevacion_m_z',
'dem_pendiente_deg_z',
'dem_orientacion_deg_z',
'eu_clay_content_z',
'eu_sand_content_z',
'eu_silt_content_z',
'eu_water_holding_capacity_z',
'eu_cn_ratio_z',
'eu_p_z',
'eu_ph_z',
'eu_as_z',
'eu_organic_carbon_octop_z',
'eu_zn_z'
]

TARGETS_TO_TEST = [
    # Shannon
    'nematode_shannon_z',
    'macro_shannon_z',
    'earthworm_shannon_z',
    'orib_shannon_z',
    'meso_shannon_z',
    'coll_shannon_z',
    'bac_shannon_z',
    'fun_shannon_z',
    'euk_shannon_z',
    'oomy_shannon_z',
    'cerc_shannon_z',
    # Richness
    'macro_order_richness_z',
    'earthworm_richness_z',
    'orib_species_richness_z',
    'meso_species_richness_z',
    'coll_species_richness_z',
    'bac_asv_richness_z',
    'fun_asv_richness_z',
    'euk_asv_richness_z',
    'oomy_asv_richness_z',
    'cerc_asv_richness_z'
]

META_TEST_SIZE = 0.3 # proporcion de eval.csv reservada como holdout para evaluar los meta-modelos

# Varios meta-modelos candidatos, todos entrenados y evaluados igual. Anade/quita libremente.
META_MODEL_FACTORIES = {
    "Ridge": lambda: Ridge(random_state=RANDOM_STATE),
    "Lasso": lambda: Lasso(alpha=0.1, random_state=RANDOM_STATE),
    "ElasticNet": lambda: ElasticNet(alpha=0.1, l1_ratio=0.5, random_state=RANDOM_STATE),
    "Linear": lambda: LinearRegression(),
    "RandomForest": lambda: RandomForestRegressor(n_estimators=200, max_depth=3, random_state=RANDOM_STATE),
}

assert all(t in TARGETS_ORDER for t in TARGETS_TO_TEST), (
    "Algun target de TARGETS_TO_TEST no esta en TARGETS_ORDER, revisa la configuracion..."
)

```

Librerias cargadas correctamente...

2.- Carga de eval.csv

```

In [2]: eval_df = pd.read_csv(EVAL_PATH)

missing_features = [f for f in FEATURES_AUTORIZADAS if f not in eval_df.columns]
missing_targets = [t for t in TARGETS_ORDER if t not in eval_df.columns]
if missing_features:
    print(f"[AVISO] Faltan {len(missing_features)} features en eval.csv: {missing_features[:5]}...")
if missing_targets:
    print(f"[AVISO] Faltan {len(missing_targets)} targets en eval.csv: {missing_targets[:5]}...")

X_eval = eval_df[FEATURES_AUTORIZADAS]
y_eval = eval_df[TARGETS_ORDER]

print(f"eval.csv: {eval_df.shape[0]} filas, {eval_df.shape[1]} columnas")
print(f"X_eval: {X_eval.shape} | y_eval: {y_eval.shape}")

```

eval.csv: 65 filas, 71 columnas
X_eval: (65, 34) | y_eval: (65, 21)

3.- Definición y carga de los modelos base

Igual que en la Prueba 4: todos los modelos son ensamblados internos de varios miembros entrenados por separado, **salvo Ridge, que es un unico modelo por target (sin ensamblado)**.

El resto de modelos, single-target (RF single-target, XGBoost single-target, un ensamblado por target) y multisalida (RF, XGBoost, RegressorChain, MLP, MLP custom loss, un ensamblado por familia), si son ensamblados: 5 miembros en todos salvo RegressorChain, que tiene 10.

`EnsembleWrapper` promedia internamente los miembros de cada ensamblado (para Ridge, con un unico miembro, no cambia el resultado), asi que a partir de aqui cada modelo base (single o multi) se trata como un unico modelo consolidado.

Ridge, RF y XGBoost se guardan como `.pkl` (misma carga con `joblib.load`). El MLP y el MLP con loss personalizada tienen sus propios pesos por miembro (`.pt`), pero el config (`.pkl`) con la arquitectura usada al entrenar es **unico por familia** (no uno por miembro).

```

In [3]: def load_sklearn(path):
        return joblib.load(path)

def load_mlp_member(weights_path, config_path):
    import torch
    import torch.nn as nn

    config = joblib.load(config_path)

    def _cfg_get(key, default):
        # El config puede venir como dict o como un objeto (p.ej. dataclass/Namespace).
        if isinstance(config, dict):
            return config.get(key, default)
        return getattr(config, key, default)

    class GenericMLP(nn.Module):
        def __init__(self, input_dim, hidden_dims, output_dim, dropout=0.0):
            super().__init__()
            layers = []
            prev_dim = input_dim
            for h in hidden_dims:
                layers.append(nn.Linear(prev_dim, h))
                layers.append(nn.ReLU())
                if dropout > 0:
                    layers.append(nn.Dropout(dropout))
                prev_dim = h
            layers.append(nn.Linear(prev_dim, output_dim))
            self.red = nn.Sequential(*layers)

        def forward(self, x):
            return self.red(x)

        def predict(self, X):
            self.eval()
            with torch.no_grad():
                X_t = torch.as_tensor(np.asarray(X), dtype=torch.float32)
                return self.red(X_t).numpy()

    model = GenericMLP(
        input_dim=_cfg_get("input_dim", len(FEATURES_AUTORIZADAS)),
        hidden_dims=_cfg_get("hidden", [64, 32]),
        output_dim=_cfg_get("output_dim", len(TARGETS_ORDER)),
        dropout=_cfg_get("dropout", 0.0),
    )
    state_dict = torch.load(Path(weights_path), map_location="cpu")
    model.load_state_dict(state_dict)
    model.eval()
    return model

class EnsembleWrapper:
    '''Modelo (single-target o multialida) guardado como ensamblado de varios miembros
    entrenados por separado. predict() promedia la prediccion de todos los miembros
    disponibles. Si falta algun miembro (archivo no encontrado, error de carga),
    simplemente se promedia con los que si se cargaron.

    kind="single": cada miembro predice directamente el target → se promedian tal cual.
    kind="multi": cada miembro predice todos los targets a la vez → primero se
    selecciona la columna del target pedido en cada miembro y despues se promedia.
    '''

    def __init__(self, key, label, members, kind, targets_order=None):
        self.key = key
        self.label = label
        self.members = members
        self.kind = kind
        self.targets_order = targets_order

    def predict(self, X, target=None):
        member_preds = []
        for model in self.members:
            preds = np.asarray(model.predict(X))
            if self.kind == "multi":
                if preds.ndim == 1:
                    preds = preds.reshape(-1, 1)
                idx = self.targets_order.index(target)
                preds = preds[:, idx]
            else:
                preds = preds.reshape(-1)
            member_preds.append(preds)
        return np.mean(np.column_stack(member_preds), axis=1)

def load_ensemble_members(loader, path_template, n_members, loader_kwargs=None, **template_kwargs):
    '''Carga los n_members ficheros de un ensamblado, tolerando fallos parciales.
    loader_kwargs son argumentos fijos que se pasan a loader() en cada miembro (p.ej.
    un config compartido por toda la familia, en vez de uno por miembro).
    Devuelve (members, errors), donde errors es una lista de (indice, tipo_error, mensaje).
    '''
    loader_kwargs = loader_kwargs or {}
    members = []
    errors = []
    for i in range(n_members):
        path = Path(path_template.format(i=i, **template_kwargs))
        try:
            members.append(loader(path, **loader_kwargs))
        except Exception as e:
            errors.append((i, type(e).__name__, str(e)))
    return members, errors

SINGLE_MODEL_CONFIGS = [

```

```

{"key": "ridge", "label": "Ridge", "loader": load_sklearn, "path_template": str(MODELS_DIR / "reg/ridge_prod_{tar
{"key": "rf_single", "label": "RF single-target", "loader": load_sklearn, "path_template": str(MODELS_DIR / "rf/
{"key": "xgb_single", "label": "XGBoost single-target", "loader": load_sklearn, "path_template": str(MODELS_DIR / "xgb/xgb_prod_{targe
}

MULTI_MODEL_CONFIGS = [
{"key": "rf_multi", "label": "RF multisalida", "loader": load_sklearn, "path_template": str(MODELS_DIR / "rf_multi/
{"key": "xgb_multi", "label": "XGBoost multisalida", "loader": load_sklearn, "path_template": str(MODELS_DIR / "xgb_multi/
{"key": "regchain", "label": "RegressorChain", "loader": load_sklearn, "path_template": str(MODELS_DIR / "chain/chain_{i}.p
{"key": "mlp_multi", "label": "MLP multisalida", "loader": load_mlp_member, "path_template": str(MODELS_DIR / "mlp/mlp_prod_{i}.p
"loader_kwargs": {"config_path": str(MODELS_DIR / "mlp/mlp_config.pkl")}},
{"key": "mlp_custom", "label": "MLP custom loss", "loader": load_mlp_member, "path_template": str(MODELS_DIR / "mlp_custom/mlp_cu
"loader_kwargs": {"config_path": str(MODELS_DIR / "mlp_custom/mlp_custom_config.pkl")}},
]

loaded_single = {} # (key, target) → EnsembleWrapper
loaded_multi = {} # key → EnsembleWrapper

for cfg in SINGLE_MODEL_CONFIGS:
    for target in TARGETS_TO_TEST:
        members, errors = load_ensemble_members(cfg["loader"], cfg["path_template"], cfg["n_members"],
                                                loader_kwargs=cfg.get("loader_kwargs"), target=target)

        if members:
            loaded_single[cfg["key"], target] = EnsembleWrapper(cfg["key"], cfg["label"], members, kind="single")
            print(f"OK {cfg['label']:22s} [{target}] cargado ({len(members)}/{cfg['n_members']} miembros)")
            if errors:
                print(f" [AVISO] {len(errors)} miembro(s) no disponible(s), se promedia solo con el resto → primer error: {errors[0]}")
        else:
            print(f"FALLO {cfg['label']:22s} [{target}] omitido → no se cargo ningun miembro (0/{cfg['n_members']})")
            if errors:
                print(f" → primer error: {errors[0][1]}: {errors[0][2]}")

for cfg in MULTI_MODEL_CONFIGS:
    members, errors = load_ensemble_members(cfg["loader"], cfg["path_template"], cfg["n_members"],
                                            loader_kwargs=cfg.get("loader_kwargs"))

    if members:
        loaded_multi[cfg["key"]] = EnsembleWrapper(cfg["key"], cfg["label"], members, kind="multi", targets_order=TARGETS_ORDER)
        print(f"OK {cfg['label']:22s} cargado ({len(members)}/{cfg['n_members']} miembros)")
        if errors:
            print(f" [AVISO] {len(errors)} miembro(s) no disponible(s), se promedia solo con el resto → primer error: {errors[0][1]}")
    else:
        print(f"FALLO {cfg['label']:22s} omitido → no se cargo ningun miembro (0/{cfg['n_members']})")
        if errors:
            print(f" → primer error: {errors[0][1]}: {errors[0][2]}")

print(f"\nModelos base disponibles: {len(loaded_single)} single-target (por target) + {len(loaded_multi)} familias multisalida")

OK Ridge [nematode_shannon_z] cargado (1/1 miembros)
OK Ridge [macro_shannon_z] cargado (1/1 miembros)
OK Ridge [earthworm_shannon_z] cargado (1/1 miembros)
OK Ridge [orib_shannon_z] cargado (1/1 miembros)
OK Ridge [meso_shannon_z] cargado (1/1 miembros)
OK Ridge [coll_shannon_z] cargado (1/1 miembros)
OK Ridge [bac_shannon_z] cargado (1/1 miembros)
OK Ridge [fun_shannon_z] cargado (1/1 miembros)
OK Ridge [euk_shannon_z] cargado (1/1 miembros)
OK Ridge [oomy_shannon_z] cargado (1/1 miembros)
OK Ridge [cerc_shannon_z] cargado (1/1 miembros)
OK Ridge [macro_order_richness_z] cargado (1/1 miembros)
OK Ridge [earthworm_richness_z] cargado (1/1 miembros)
OK Ridge [orib_species_richness_z] cargado (1/1 miembros)
OK Ridge [meso_species_richness_z] cargado (1/1 miembros)
OK Ridge [coll_species_richness_z] cargado (1/1 miembros)
OK Ridge [bac_asv_richness_z] cargado (1/1 miembros)
OK Ridge [fun_asv_richness_z] cargado (1/1 miembros)
OK Ridge [euk_asv_richness_z] cargado (1/1 miembros)
OK Ridge [oomy_asv_richness_z] cargado (1/1 miembros)
OK Ridge [cerc_asv_richness_z] cargado (1/1 miembros)
OK RF single-target [nematode_shannon_z] cargado (5/5 miembros)
OK RF single-target [macro_shannon_z] cargado (5/5 miembros)
OK RF single-target [earthworm_shannon_z] cargado (5/5 miembros)
OK RF single-target [orib_shannon_z] cargado (5/5 miembros)
OK RF single-target [meso_shannon_z] cargado (5/5 miembros)
OK RF single-target [coll_shannon_z] cargado (5/5 miembros)
OK RF single-target [bac_shannon_z] cargado (5/5 miembros)
OK RF single-target [fun_shannon_z] cargado (5/5 miembros)
OK RF single-target [euk_shannon_z] cargado (5/5 miembros)
OK RF single-target [oomy_shannon_z] cargado (5/5 miembros)
OK RF single-target [cerc_shannon_z] cargado (5/5 miembros)
OK RF single-target [macro_order_richness_z] cargado (5/5 miembros)
OK RF single-target [earthworm_richness_z] cargado (5/5 miembros)
OK RF single-target [orib_species_richness_z] cargado (5/5 miembros)
OK RF single-target [meso_species_richness_z] cargado (5/5 miembros)
OK RF single-target [coll_species_richness_z] cargado (5/5 miembros)
OK RF single-target [bac_asv_richness_z] cargado (5/5 miembros)
OK RF single-target [fun_asv_richness_z] cargado (5/5 miembros)
OK RF single-target [euk_asv_richness_z] cargado (5/5 miembros)
OK RF single-target [oomy_asv_richness_z] cargado (5/5 miembros)
OK RF single-target [cerc_asv_richness_z] cargado (5/5 miembros)

```

```

OK      XGBoost single-target [nematode_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [macro_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [earthworm_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [orib_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [meso_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [coll_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [bac_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [fun_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [euk_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [oomy_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [cerc_shannon_z] cargado (5/5 miembros)
OK      XGBoost single-target [macro_order_richness_z] cargado (5/5 miembros)
OK      XGBoost single-target [earthworm_richness_z] cargado (5/5 miembros)
OK      XGBoost single-target [orib_species_richness_z] cargado (5/5 miembros)
OK      XGBoost single-target [meso_species_richness_z] cargado (5/5 miembros)
OK      XGBoost single-target [coll_species_richness_z] cargado (5/5 miembros)
OK      XGBoost single-target [bac_asv_richness_z] cargado (5/5 miembros)
OK      XGBoost single-target [fun_asv_richness_z] cargado (5/5 miembros)
OK      XGBoost single-target [euk_asv_richness_z] cargado (5/5 miembros)
OK      XGBoost single-target [oomy_asv_richness_z] cargado (5/5 miembros)
OK      XGBoost single-target [cerc_asv_richness_z] cargado (5/5 miembros)
OK      RF multisalida      cargado (5/5 miembros)
OK      XGBoost multisalida cargado (5/5 miembros)
OK      RegressorChain      cargado (10/10 miembros)
OK      MLP multisalida     cargado (5/5 miembros)
OK      MLP custom loss     cargado (5/5 miembros)

```

Modelos base disponibles: 63 single-target (por target) + 5 familias multisalida

4.- Smoke test sobre eval.csv completo

Igual que en la Prueba 4: se predice una unica vez sobre todo eval.csv y se reutilizan las predicciones despues, tanto para entrenar como para evaluar el meta-modelo (respetando la particion train/holdout de la seccion 5).

```

In [4]: def smoke_test(wrapper, X, y_true, target):
    try:
        preds = wrapper.predict(X, target=target)
    except Exception as e:
        print(f"[SMOKE TEST] {wrapper.label:22s} | {target:22s} | ERROR al predecir -> {type(e).__name__}: {e}")
        return None

    preds = np.asarray(preds, dtype=float).reshape(-1)
    shape_ok = preds.shape[0] == len(X)
    n_nan = int(np.isnan(preds).sum())
    n_inf = int(np.isinf(preds).sum())
    ok = shape_ok and n_nan == 0 and n_inf == 0
    r2 = r2_score(y_true, preds) if ok else float("nan")
    status = "OK" if ok else "REVISAR"
    print(f"[SMOKE TEST] {wrapper.label:22s} | {target:22s} | filas={len(preds):5d} | "
          f"NaN={n_nan} | Inf={n_inf} | R2={r2:.4f} | {status}")
    return preds if ok else None

# predictions[target][label] = np.array de predicciones sobre TODO eval.csv (solo si paso el smoke test)
predictions = {}
for t in TARGETS_TO_TEST:
    for target in TARGETS_TO_TEST:
        y_true_t = y_eval[target].values
        print(f"\n--- {target} ---")

        for (key, t), wrapper in loaded_single.items():
            if t != target:
                continue
            preds = smoke_test(wrapper, X_eval, y_true_t, target)
            if preds is not None:
                predictions[target][wrapper.label] = preds

        for key, wrapper in loaded_multi.items():
            preds = smoke_test(wrapper, X_eval, y_true_t, target)
            if preds is not None:
                predictions[target][wrapper.label] = preds

--- nematode_shannon_z ---
[SMOKE TEST] Ridge | nematode_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.0112 | OK
[SMOKE TEST] RF single-target | nematode_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.1366 | OK
[SMOKE TEST] XGBoost single-target | nematode_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.1637 | OK
[SMOKE TEST] RF multisalida | nematode_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.1545 | OK
[SMOKE TEST] XGBoost multisalida | nematode_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.2228 | OK
[SMOKE TEST] RegressorChain | nematode_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.1467 | OK
[SMOKE TEST] MLP multisalida | nematode_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.0829 | OK
[SMOKE TEST] MLP custom loss | nematode_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.0668 | OK

--- macro_shannon_z ---
[SMOKE TEST] Ridge | macro_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.1257 | OK
[SMOKE TEST] RF single-target | macro_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.2797 | OK
[SMOKE TEST] XGBoost single-target | macro_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.2601 | OK
[SMOKE TEST] RF multisalida | macro_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.2000 | OK
[SMOKE TEST] XGBoost multisalida | macro_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.3771 | OK
[SMOKE TEST] RegressorChain | macro_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.2804 | OK
[SMOKE TEST] MLP multisalida | macro_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.2396 | OK
[SMOKE TEST] MLP custom loss | macro_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.2704 | OK

--- earthworm_shannon_z ---
[SMOKE TEST] Ridge | earthworm_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.2395 | OK
[SMOKE TEST] RF single-target | earthworm_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.5059 | OK
[SMOKE TEST] XGBoost single-target | earthworm_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.4946 | OK
[SMOKE TEST] RF multisalida | earthworm_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.4160 | OK
[SMOKE TEST] XGBoost multisalida | earthworm_shannon_z | filas= 65 | NaN=0 | Inf=0 | R2= 0.5375 | OK

```

[SMOKE TEST]	RegressorChain	earthworm_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.4876	OK
[SMOKE TEST]	MLP multisalida	earthworm_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.3538	OK
[SMOKE TEST]	MLP custom loss	earthworm_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.3770	OK
--- orib_shannon_z ---									
[SMOKE TEST]	Ridge	orib_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1137	OK
[SMOKE TEST]	RF single-target	orib_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1644	OK
[SMOKE TEST]	XGBoost single-target	orib_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1147	OK
[SMOKE TEST]	RF multisalida	orib_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1693	OK
[SMOKE TEST]	XGBoost multisalida	orib_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.2275	OK
[SMOKE TEST]	RegressorChain	orib_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.2069	OK
[SMOKE TEST]	MLP multisalida	orib_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.2250	OK
[SMOKE TEST]	MLP custom loss	orib_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.2552	OK
--- meso_shannon_z ---									
[SMOKE TEST]	Ridge	meso_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.2499	OK
[SMOKE TEST]	RF single-target	meso_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.1895	OK
[SMOKE TEST]	XGBoost single-target	meso_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.1868	OK
[SMOKE TEST]	RF multisalida	meso_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.1178	OK
[SMOKE TEST]	XGBoost multisalida	meso_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.2861	OK
[SMOKE TEST]	RegressorChain	meso_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.1640	OK
[SMOKE TEST]	MLP multisalida	meso_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.4925	OK
[SMOKE TEST]	MLP custom loss	meso_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.4289	OK
--- coll_shannon_z ---									
[SMOKE TEST]	Ridge	coll_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.4998	OK
[SMOKE TEST]	RF single-target	coll_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.4168	OK
[SMOKE TEST]	XGBoost single-target	coll_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.3312	OK
[SMOKE TEST]	RF multisalida	coll_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.1953	OK
[SMOKE TEST]	XGBoost multisalida	coll_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.3229	OK
[SMOKE TEST]	RegressorChain	coll_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.6087	OK
[SMOKE TEST]	MLP multisalida	coll_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	1.2378	OK
[SMOKE TEST]	MLP custom loss	coll_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	1.2015	OK
--- bac_shannon_z ---									
[SMOKE TEST]	Ridge	bac_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0812	OK
[SMOKE TEST]	RF single-target	bac_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0037	OK
[SMOKE TEST]	XGBoost single-target	bac_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0092	OK
[SMOKE TEST]	RF multisalida	bac_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0290	OK
[SMOKE TEST]	XGBoost multisalida	bac_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0151	OK
[SMOKE TEST]	RegressorChain	bac_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0288	OK
[SMOKE TEST]	MLP multisalida	bac_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0334	OK
[SMOKE TEST]	MLP custom loss	bac_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.1218	OK
--- fun_shannon_z ---									
[SMOKE TEST]	Ridge	fun_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0161	OK
[SMOKE TEST]	RF single-target	fun_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0337	OK
[SMOKE TEST]	XGBoost single-target	fun_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0206	OK
[SMOKE TEST]	RF multisalida	fun_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0127	OK
[SMOKE TEST]	XGBoost multisalida	fun_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0502	OK
[SMOKE TEST]	RegressorChain	fun_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0219	OK
[SMOKE TEST]	MLP multisalida	fun_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.1246	OK
[SMOKE TEST]	MLP custom loss	fun_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0672	OK
--- euk_shannon_z ---									
[SMOKE TEST]	Ridge	euk_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0407	OK
[SMOKE TEST]	RF single-target	euk_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1575	OK
[SMOKE TEST]	XGBoost single-target	euk_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0912	OK
[SMOKE TEST]	RF multisalida	euk_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1378	OK
[SMOKE TEST]	XGBoost multisalida	euk_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0886	OK
[SMOKE TEST]	RegressorChain	euk_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1624	OK
[SMOKE TEST]	MLP multisalida	euk_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1451	OK
[SMOKE TEST]	MLP custom loss	euk_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1025	OK
--- oomy_shannon_z ---									
[SMOKE TEST]	Ridge	oomy_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0857	OK
[SMOKE TEST]	RF single-target	oomy_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0998	OK
[SMOKE TEST]	XGBoost single-target	oomy_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0965	OK
[SMOKE TEST]	RF multisalida	oomy_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1252	OK
[SMOKE TEST]	XGBoost multisalida	oomy_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0620	OK
[SMOKE TEST]	RegressorChain	oomy_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0913	OK
[SMOKE TEST]	MLP multisalida	oomy_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.1362	OK
[SMOKE TEST]	MLP custom loss	oomy_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0429	OK
--- cerc_shannon_z ---									
[SMOKE TEST]	Ridge	cerc_shannon_z	filas=	65	NaN=0	Inf=0	R2=	0.0155	OK
[SMOKE TEST]	RF single-target	cerc_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0404	OK
[SMOKE TEST]	XGBoost single-target	cerc_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0414	OK
[SMOKE TEST]	RF multisalida	cerc_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0041	OK
[SMOKE TEST]	XGBoost multisalida	cerc_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0330	OK
[SMOKE TEST]	RegressorChain	cerc_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0006	OK
[SMOKE TEST]	MLP multisalida	cerc_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0055	OK
[SMOKE TEST]	MLP custom loss	cerc_shannon_z	filas=	65	NaN=0	Inf=0	R2=-	0.0613	OK
--- macro_order_richness_z ---									
[SMOKE TEST]	Ridge	macro_order_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.1521	OK
[SMOKE TEST]	RF single-target	macro_order_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.3058	OK
[SMOKE TEST]	XGBoost single-target	macro_order_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.3082	OK
[SMOKE TEST]	RF multisalida	macro_order_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.2532	OK
[SMOKE TEST]	XGBoost multisalida	macro_order_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.4013	OK
[SMOKE TEST]	RegressorChain	macro_order_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.4069	OK
[SMOKE TEST]	MLP multisalida	macro_order_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.3447	OK
[SMOKE TEST]	MLP custom loss	macro_order_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.3581	OK
--- earthworm_richness_z ---									
[SMOKE TEST]	Ridge	earthworm_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.2789	OK
[SMOKE TEST]	RF single-target	earthworm_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.5492	OK
[SMOKE TEST]	XGBoost single-target	earthworm_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.5171	OK
[SMOKE TEST]	RF multisalida	earthworm_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.4509	OK
[SMOKE TEST]	XGBoost multisalida	earthworm_richness_z	filas=	65	NaN=0	Inf=0	R2=	0.5893	OK

[SMOKE TEST] RegressorChain	earthworm_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.5359	OK
[SMOKE TEST] MLP multisalida	earthworm_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.4628	OK
[SMOKE TEST] MLP custom loss	earthworm_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.4854	OK

--- orib_species_richness_z ---

[SMOKE TEST] Ridge	orib_species_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0921	OK
[SMOKE TEST] RF single-target	orib_species_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2407	OK
[SMOKE TEST] XGBoost single-target	orib_species_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1259	OK
[SMOKE TEST] RF multisalida	orib_species_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2386	OK
[SMOKE TEST] XGBoost multisalida	orib_species_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2800	OK
[SMOKE TEST] RegressorChain	orib_species_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2026	OK
[SMOKE TEST] MLP multisalida	orib_species_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2783	OK
[SMOKE TEST] MLP custom loss	orib_species_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2981	OK

--- meso_species_richness_z ---

[SMOKE TEST] Ridge	meso_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0959	OK
[SMOKE TEST] RF single-target	meso_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0453	OK
[SMOKE TEST] XGBoost single-target	meso_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0592	OK
[SMOKE TEST] RF multisalida	meso_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0255	OK
[SMOKE TEST] XGBoost multisalida	meso_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.1146	OK
[SMOKE TEST] RegressorChain	meso_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0400	OK
[SMOKE TEST] MLP multisalida	meso_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.2681	OK
[SMOKE TEST] MLP custom loss	meso_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.2198	OK

--- coll_species_richness_z ---

[SMOKE TEST] Ridge	coll_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.7341	OK
[SMOKE TEST] RF single-target	coll_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.5461	OK
[SMOKE TEST] XGBoost single-target	coll_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.5803	OK
[SMOKE TEST] RF multisalida	coll_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.2920	OK
[SMOKE TEST] XGBoost multisalida	coll_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.6465	OK
[SMOKE TEST] RegressorChain	coll_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.5799	OK
[SMOKE TEST] MLP multisalida	coll_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-2.0859	OK
[SMOKE TEST] MLP custom loss	coll_species_richness_z	filas=	65	NaN=0	Inf=0	R2=-1.9873	OK

--- bac_asv_richness_z ---

[SMOKE TEST] Ridge	bac_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0761	OK
[SMOKE TEST] RF single-target	bac_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0004	OK
[SMOKE TEST] XGBoost single-target	bac_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0014	OK
[SMOKE TEST] RF multisalida	bac_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0044	OK
[SMOKE TEST] XGBoost multisalida	bac_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0155	OK
[SMOKE TEST] RegressorChain	bac_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0052	OK
[SMOKE TEST] MLP multisalida	bac_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0799	OK
[SMOKE TEST] MLP custom loss	bac_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.1811	OK

--- fun_asv_richness_z ---

[SMOKE TEST] Ridge	fun_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0087	OK
[SMOKE TEST] RF single-target	fun_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0144	OK
[SMOKE TEST] XGBoost single-target	fun_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0242	OK
[SMOKE TEST] RF multisalida	fun_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0068	OK
[SMOKE TEST] XGBoost multisalida	fun_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0662	OK
[SMOKE TEST] RegressorChain	fun_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0186	OK
[SMOKE TEST] MLP multisalida	fun_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0105	OK
[SMOKE TEST] MLP custom loss	fun_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0069	OK

--- euk_asv_richness_z ---

[SMOKE TEST] Ridge	euk_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0400	OK
[SMOKE TEST] RF single-target	euk_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2360	OK
[SMOKE TEST] XGBoost single-target	euk_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1671	OK
[SMOKE TEST] RF multisalida	euk_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1903	OK
[SMOKE TEST] XGBoost multisalida	euk_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2233	OK
[SMOKE TEST] RegressorChain	euk_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2690	OK
[SMOKE TEST] MLP multisalida	euk_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2470	OK
[SMOKE TEST] MLP custom loss	euk_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1970	OK

--- oomy_asv_richness_z ---

[SMOKE TEST] Ridge	oomy_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1035	OK
[SMOKE TEST] RF single-target	oomy_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1895	OK
[SMOKE TEST] XGBoost single-target	oomy_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1776	OK
[SMOKE TEST] RF multisalida	oomy_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1917	OK
[SMOKE TEST] XGBoost multisalida	oomy_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1650	OK
[SMOKE TEST] RegressorChain	oomy_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.2019	OK
[SMOKE TEST] MLP multisalida	oomy_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0640	OK
[SMOKE TEST] MLP custom loss	oomy_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0188	OK

--- cerc_asv_richness_z ---

[SMOKE TEST] Ridge	cerc_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1019	OK
[SMOKE TEST] RF single-target	cerc_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1207	OK
[SMOKE TEST] XGBoost single-target	cerc_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1227	OK
[SMOKE TEST] RF multisalida	cerc_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1171	OK
[SMOKE TEST] XGBoost multisalida	cerc_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0983	OK
[SMOKE TEST] RegressorChain	cerc_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.1171	OK
[SMOKE TEST] MLP multisalida	cerc_asv_richness_z	filas=	65	NaN=0	Inf=0	R2= 0.0285	OK
[SMOKE TEST] MLP custom loss	cerc_asv_richness_z	filas=	65	NaN=0	Inf=0	R2=-0.0845	OK

5.- Particion meta-train / meta-holdout

Se separan las filas de `eval.csv` en dos bloques usando los mismos indices para todos los targets: uno para entrenar el meta-modelo y otro (holdout) para evaluarlo despues, sin que haya visto esas filas durante el entrenamiento.

```
In [5]: idx_all = np.arange(len(eval_df))
idx_train, idx_holdout = train_test_split(idx_all, test_size=META_TEST_SIZE, random_state=RANDOM_STATE)

print(f"Filas totales en eval.csv: {len(idx_all)}")
print(f"Filas para entrenar el meta-modelo (meta-train): {len(idx_train)}")
print(f"Filas para evaluar el meta-modelo (holdout): {len(idx_holdout)}")
```

```
Filas totales en eval.csv: 65
Filas para entrenar el meta-modelo (meta-train): 45
Filas para evaluar el meta-modelo (holdout): 20
```

6.- Entrenamiento de los meta-modelos por target

Para cada target y cada candidato de `META_MODEL_FACTORIES`, la entrada es la matriz de predicciones de todos los modelos base disponibles (una columna por modelo) sobre las filas de meta-train, y la salida es el valor real de ese target en esas mismas filas.

```
In [6]: meta_models = {} # target → {"model_labels": [...], "models": {nombre_meta: modelo_entrenado}}
stacked_features = {} # target → matriz (n_filas_eval x n_modelos_base), mismo orden que eval_df

for target in TARGETS_TO_TEST:
    model_labels = list(predictions[target].keys())
    if not model_labels:
        print(f"[AVISO] {target}: no hay modelos base disponibles, no se pueden entrenar los meta-modelos.")
        continue

    X_meta = np.column_stack([predictions[target][lbl] for lbl in model_labels])
    stacked_features[target] = X_meta

    y_target = y_eval[target].values
    X_meta_train = X_meta[idx_train]
    y_meta_train = y_target[idx_train]

    trained = {}
    for meta_name, factory in META_MODEL_FACTORIES.items():
        meta_model = factory()
        meta_model.fit(X_meta_train, y_meta_train)
        trained[meta_name] = meta_model

    meta_models[target] = {"model_labels": model_labels, "models": trained}
    print(f"{target}: {len(trained)} meta-modelos entrenados con {len(model_labels)} modelos base → {list(trained)}")
```

```
nematode_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
macro_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
earthworm_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
orib_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
meso_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
coll_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
bac_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
fun_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
euk_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
oomy_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
cerc_shannon_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
macro_order_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
earthworm_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
orib_species_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
meso_species_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
coll_species_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
bac_asv_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
fun_asv_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
euk_asv_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
oomy_asv_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
cerc_asv_richness_z: 5 meta-modelos entrenados con 8 modelos base → ['Ridge', 'Lasso', 'ElasticNet', 'Linear', 'RandomForest']
```

7.- Smoke test de los meta-modelos sobre el holdout

Mismas comprobaciones que antes (sin error, sin NaN/Inf, tamaño correcto), aplicadas a cada meta-modelo sobre las filas de holdout que no ha visto en el entrenamiento. También se guardan aquí las predicciones de cada modelo base y del ensamblado simple por media, recortadas al mismo holdout, para poder comparar todo en igualdad de condiciones en la sección 8.

```
In [7]: holdout_predictions = {} for t in TARGETS_TO_TEST:

for target in TARGETS_TO_TEST:
    if target not in meta_models:
        continue

    y_true_holdout = y_eval[target].values[idx_holdout]
    print(f"\n--- {target} (holdout, {len(idx_holdout)} filas) ---")

    # Modelos base, recortados al holdout
    for label in meta_models[target]["model_labels"]:
        preds_full = predictions[target][label]
        preds_holdout = np.asarray(preds_full, dtype=float)[idx_holdout]
        n_nan = int(np.isnan(preds_holdout).sum())
        n_inf = int(np.isinf(preds_holdout).sum())
        ok = n_nan == 0 and n_inf == 0
        r2 = r2_score(y_true_holdout, preds_holdout) if ok else float("nan")
        status = "OK" if ok else "REVISAR"
        print(f"[SMOKE TEST] {label:22s} | filas={len(preds_holdout):5d} | NaN={n_nan} | Inf={n_inf} | R2={r2: .4f} | {status}")
        if ok:
            holdout_predictions[target][label] = preds_holdout

    # Ensamblado simple por media, calculado solo con las filas del holdout
    model_labels = meta_models[target]["model_labels"]
    stacked_holdout = np.column_stack([predictions[target][lbl] for lbl in model_labels])[idx_holdout]
    mean_ensemble_holdout = stacked_holdout.mean(axis=1)
    holdout_predictions[target]["Ensamblado (media)"] = mean_ensemble_holdout

    # Cada meta-modelo candidato
    X_meta_holdout = stacked_features[target][idx_holdout]
    for meta_name, meta_model in meta_models[target]["models"].items():
        label = f"Meta-modelo ({meta_name})"
        try:
            meta_preds = np.asarray(meta_model.predict(X_meta_holdout, dtype=float).reshape(-1))
            n_nan = int(np.isnan(meta_preds).sum())
            n_inf = int(np.isinf(meta_preds).sum())
            ok = meta_preds.shape[0] == len(idx_holdout) and n_nan == 0 and n_inf == 0
            r2 = r2_score(y_true_holdout, meta_preds) if ok else float("nan")
            status = "OK" if ok else "REVISAR"
            print(f"[SMOKE TEST] {label:22s} | filas={len(meta_preds):5d} | NaN={n_nan} | Inf={n_inf} | R2={r2: .4f} | {status}")
            if ok:
                holdout_predictions[target][label] = meta_preds
        except Exception as e:
            print(f"[SMOKE TEST] {label:22s} | ERROR al predecir → {type(e).__name__}: {e}")
```



```

--- nematode_shannon_z (holdout, 20 filas) ---
[SMOKE TEST] Ridge | filas= 20 | NaN=0 | Inf=0 | R2=-0.0695 | OK
[SMOKE TEST] RF single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.1074 | OK
[SMOKE TEST] XGBoost single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.1346 | OK
[SMOKE TEST] RF multisalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.0853 | OK
[SMOKE TEST] XGBoost multisalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.2808 | OK
[SMOKE TEST] RegressorChain | filas= 20 | NaN=0 | Inf=0 | R2= 0.1490 | OK
[SMOKE TEST] MLP multisalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.0073 | OK
[SMOKE TEST] MLP custom loss | filas= 20 | NaN=0 | Inf=0 | R2= 0.0617 | OK
[SMOKE TEST] Meta-modelo (Ridge) | filas= 20 | NaN=0 | Inf=0 | R2= 0.2599 | OK
[SMOKE TEST] Meta-modelo (Lasso) | filas= 20 | NaN=0 | Inf=0 | R2= 0.2238 | OK
[SMOKE TEST] Meta-modelo (ElasticNet) | filas= 20 | NaN=0 | Inf=0 | R2= 0.2206 | OK
[SMOKE TEST] Meta-modelo (Linear) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1860 | OK
[SMOKE TEST] Meta-modelo (RandomForest) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1941 | OK

--- macro_shannon_z (holdout, 20 filas) ---
[SMOKE TEST] Ridge | filas= 20 | NaN=0 | Inf=0 | R2=-0.0129 | OK
[SMOKE TEST] RF single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.3044 | OK
[SMOKE TEST] XGBoost single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.3127 | OK
[SMOKE TEST] RF multisalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.1926 | OK
[SMOKE TEST] XGBoost multisalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.3703 | OK
[SMOKE TEST] RegressorChain | filas= 20 | NaN=0 | Inf=0 | R2= 0.3722 | OK
[SMOKE TEST] MLP multisalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.2301 | OK
[SMOKE TEST] MLP custom loss | filas= 20 | NaN=0 | Inf=0 | R2= 0.3217 | OK
[SMOKE TEST] Meta-modelo (Ridge) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1676 | OK
[SMOKE TEST] Meta-modelo (Lasso) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1009 | OK
[SMOKE TEST] Meta-modelo (ElasticNet) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1222 | OK
[SMOKE TEST] Meta-modelo (Linear) | filas= 20 | NaN=0 | Inf=0 | R2= 0.0225 | OK
[SMOKE TEST] Meta-modelo (RandomForest) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1182 | OK

--- earthworm_shannon_z (holdout, 20 filas) ---
[SMOKE TEST] Ridge | filas= 20 | NaN=0 | Inf=0 | R2=-0.1160 | OK
[SMOKE TEST] RF single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.3653 | OK
[SMOKE TEST] XGBoost single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.3157 | OK
[SMOKE TEST] RF multisalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.3560 | OK
[SMOKE TEST] XGBoost multisalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.3227 | OK
[SMOKE TEST] RegressorChain | filas= 20 | NaN=0 | Inf=0 | R2= 0.3665 | OK
[SMOKE TEST] MLP multisalida | filas= 20 | NaN=0 | Inf=0 | R2=-0.0194 | OK
[SMOKE TEST] MLP custom loss | filas= 20 | NaN=0 | Inf=0 | R2= 0.0703 | OK
[SMOKE TEST] Meta-modelo (Ridge) | filas= 20 | NaN=0 | Inf=0 | R2= 0.3012 | OK
[SMOKE TEST] Meta-modelo (Lasso) | filas= 20 | NaN=0 | Inf=0 | R2= 0.3263 | OK
[SMOKE TEST] Meta-modelo (ElasticNet) | filas= 20 | NaN=0 | Inf=0 | R2= 0.3273 | OK
[SMOKE TEST] Meta-modelo (Linear) | filas= 20 | NaN=0 | Inf=0 | R2=-0.2114 | OK
[SMOKE TEST] Meta-modelo (RandomForest) | filas= 20 | NaN=0 | Inf=0 | R2= 0.3237 | OK

--- orib_shannon_z (holdout, 20 filas) ---
[SMOKE TEST] Ridge | filas= 20 | NaN=0 | Inf=0 | R2=-0.0291 | OK
[SMOKE TEST] RF single-target | filas= 20 | NaN=0 | Inf=0 | R2=-0.0202 | OK
[SMOKE TEST] XGBoost single-target | filas= 20 | NaN=0 | Inf=0 | R2=-0.0462 | OK
[SMOKE TEST] RF multisalida | filas= 20 | NaN=0 | Inf=0 | R2=-0.0127 | OK
[SMOKE TEST] XGBoost multisalida | filas= 20 | NaN=0 | Inf=0 | R2=-0.0546 | OK
[SMOKE TEST] RegressorChain | filas= 20 | NaN=0 | Inf=0 | R2=-0.0302 | OK
[SMOKE TEST] MLP multisalida | filas= 20 | NaN=0 | Inf=0 | R2=-0.0543 | OK
[SMOKE TEST] MLP custom loss | filas= 20 | NaN=0 | Inf=0 | R2=-0.0014 | OK
[SMOKE TEST] Meta-modelo (Ridge) | filas= 20 | NaN=0 | Inf=0 | R2=-0.0782 | OK
[SMOKE TEST] Meta-modelo (Lasso) | filas= 20 | NaN=0 | Inf=0 | R2= 0.0146 | OK
[SMOKE TEST] Meta-modelo (ElasticNet) | filas= 20 | NaN=0 | Inf=0 | R2=-0.0269 | OK
[SMOKE TEST] Meta-modelo (Linear) | filas= 20 | NaN=0 | Inf=0 | R2=-0.1755 | OK

```

[SMOKE TEST] Meta-modelo (RandomForest) | filas= 20 | NaN=0 | Inf=0 | R2=-0.2093 | OK

[SMOKE TEST]	Meta-modelo (Linear)	filas=	20	NaN=0	Inf=0	R2= 0.0356	OK
[SMOKE TEST]	Meta-modelo (RandomForest)	filas=	20	NaN=0	Inf=0	R2=-0.1280	OK
--- macro_order_richness_z (holdout, 20 filas) ---							
[SMOKE TEST]	Ridge	filas=	20	NaN=0	Inf=0	R2= 0.0627	OK
[SMOKE TEST]	RF single-target	filas=	20	NaN=0	Inf=0	R2= 0.3932	OK
[SMOKE TEST]	XGBoost single-target	filas=	20	NaN=0	Inf=0	R2= 0.4325	OK
[SMOKE TEST]	RF multitalida	filas=	20	NaN=0	Inf=0	R2= 0.2537	OK
[SMOKE TEST]	XGBoost multitalida	filas=	20	NaN=0	Inf=0	R2= 0.5090	OK
[SMOKE TEST]	RegressorChain	filas=	20	NaN=0	Inf=0	R2= 0.3964	OK
[SMOKE TEST]	MLP multitalida	filas=	20	NaN=0	Inf=0	R2= 0.3583	OK
[SMOKE TEST]	MLP custom loss	filas=	20	NaN=0	Inf=0	R2= 0.4312	OK
[SMOKE TEST]	Meta-modelo (Ridge)	filas=	20	NaN=0	Inf=0	R2= 0.3097	OK
[SMOKE TEST]	Meta-modelo (Lasso)	filas=	20	NaN=0	Inf=0	R2= 0.1530	OK
[SMOKE TEST]	Meta-modelo (ElasticNet)	filas=	20	NaN=0	Inf=0	R2= 0.2270	OK
[SMOKE TEST]	Meta-modelo (Linear)	filas=	20	NaN=0	Inf=0	R2= 0.3036	OK
[SMOKE TEST]	Meta-modelo (RandomForest)	filas=	20	NaN=0	Inf=0	R2= 0.3142	OK
--- earthworm_richness_z (holdout, 20 filas) ---							
[SMOKE TEST]	Ridge	filas=	20	NaN=0	Inf=0	R2=-0.1531	OK
[SMOKE TEST]	RF single-target	filas=	20	NaN=0	Inf=0	R2= 0.5028	OK
[SMOKE TEST]	XGBoost single-target	filas=	20	NaN=0	Inf=0	R2= 0.4989	OK
[SMOKE TEST]	RF multitalida	filas=	20	NaN=0	Inf=0	R2= 0.4353	OK
[SMOKE TEST]	XGBoost multitalida	filas=	20	NaN=0	Inf=0	R2= 0.5087	OK
[SMOKE TEST]	RegressorChain	filas=	20	NaN=0	Inf=0	R2= 0.4625	OK
[SMOKE TEST]	MLP multitalida	filas=	20	NaN=0	Inf=0	R2= 0.1671	OK
[SMOKE TEST]	MLP custom loss	filas=	20	NaN=0	Inf=0	R2= 0.2336	OK
[SMOKE TEST]	Meta-modelo (Ridge)	filas=	20	NaN=0	Inf=0	R2= 0.5225	OK
[SMOKE TEST]	Meta-modelo (Lasso)	filas=	20	NaN=0	Inf=0	R2= 0.5175	OK
[SMOKE TEST]	Meta-modelo (ElasticNet)	filas=	20	NaN=0	Inf=0	R2= 0.4737	OK
[SMOKE TEST]	Meta-modelo (Linear)	filas=	20	NaN=0	Inf=0	R2= 0.4934	OK
[SMOKE TEST]	Meta-modelo (RandomForest)	filas=	20	NaN=0	Inf=0	R2= 0.1883	OK
--- orib_species_richness_z (holdout, 20 filas) ---							
[SMOKE TEST]	Ridge	filas=	20	NaN=0	Inf=0	R2=-0.1141	OK
[SMOKE TEST]	RF single-target	filas=	20	NaN=0	Inf=0	R2=-0.0893	OK
[SMOKE TEST]	XGBoost single-target	filas=	20	NaN=0	Inf=0	R2=-0.0734	OK
[SMOKE TEST]	RF multitalida	filas=	20	NaN=0	Inf=0	R2=-0.0545	OK
[SMOKE TEST]	XGBoost multitalida	filas=	20	NaN=0	Inf=0	R2=-0.1811	OK
[SMOKE TEST]	RegressorChain	filas=	20	NaN=0	Inf=0	R2=-0.0834	OK
[SMOKE TEST]	MLP multitalida	filas=	20	NaN=0	Inf=0	R2=-0.2441	OK
[SMOKE TEST]	MLP custom loss	filas=	20	NaN=0	Inf=0	R2=-0.2714	OK
[SMOKE TEST]	Meta-modelo (Ridge)	filas=	20	NaN=0	Inf=0	R2=-0.4362	OK
[SMOKE TEST]	Meta-modelo (Lasso)	filas=	20	NaN=0	Inf=0	R2=-0.3159	OK
[SMOKE TEST]	Meta-modelo (ElasticNet)	filas=	20	NaN=0	Inf=0	R2=-0.3580	OK
[SMOKE TEST]	Meta-modelo (Linear)	filas=	20	NaN=0	Inf=0	R2=-0.2950	OK
[SMOKE TEST]	Meta-modelo (RandomForest)	filas=	20	NaN=0	Inf=0	R2=-0.5907	OK
--- meso_species_richness_z (holdout, 20 filas) ---							
[SMOKE TEST]	Ridge	filas=	20	NaN=0	Inf=0	R2=-0.0381	OK
[SMOKE TEST]	RF single-target	filas=	20	NaN=0	Inf=0	R2= 0.0531	OK
[SMOKE TEST]	XGBoost single-target	filas=	20	NaN=0	Inf=0	R2= 0.0512	OK
[SMOKE TEST]	RF multitalida	filas=	20	NaN=0	Inf=0	R2= 0.0116	OK
[SMOKE TEST]	XGBoost multitalida	filas=	20	NaN=0	Inf=0	R2=-0.0264	OK
[SMOKE TEST]	RegressorChain	filas=	20	NaN=0	Inf=0	R2= 0.0499	OK
[SMOKE TEST]	MLP multitalida	filas=	20	NaN=0	Inf=0	R2=-0.4126	OK
[SMOKE TEST]	MLP custom loss	filas=	20	NaN=0	Inf=0	R2=-0.3581	OK
[SMOKE TEST]	Meta-modelo (Ridge)	filas=	20	NaN=0	Inf=0	R2=-0.1662	OK
[SMOKE TEST]	Meta-modelo (Lasso)	filas=	20	NaN=0	Inf=0	R2=-0.0630	OK
[SMOKE TEST]	Meta-modelo (ElasticNet)	filas=	20	NaN=0	Inf=0	R2=-0.0636	OK
[SMOKE TEST]	Meta-modelo (Linear)	filas=	20	NaN=0	Inf=0	R2=-0.1760	OK
[SMOKE TEST]	Meta-modelo (RandomForest)	filas=	20	NaN=0	Inf=0	R2=-0.2422	OK
--- coll_species_richness_z (holdout, 20 filas) ---							

```
[SMOKE TEST] Meta-modelo (ElasticNet) | filas= 20 | NaN=0 | Inf=0 | R2=-0.0286 | OK
[SMOKE TEST] Meta-modelo (Linear) | filas= 20 | NaN=0 | Inf=0 | R2=-0.0661 | OK
[SMOKE TEST] Meta-modelo (RandomForest) | filas= 20 | NaN=0 | Inf=0 | R2=-0.2787 | OK

--- euk_asv_richness_z (holdout, 20 filas) ---
[SMOKE TEST] Ridge | filas= 20 | NaN=0 | Inf=0 | R2= 0.1997 | OK
[SMOKE TEST] RF single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.2195 | OK
[SMOKE TEST] XGBoost single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.1091 | OK
[SMOKE TEST] RF multiasalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.1859 | OK
[SMOKE TEST] XGBoost multiasalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.0789 | OK
[SMOKE TEST] RegressorChain | filas= 20 | NaN=0 | Inf=0 | R2= 0.2012 | OK
[SMOKE TEST] MLP multiasalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.1930 | OK
[SMOKE TEST] MLP custom loss | filas= 20 | NaN=0 | Inf=0 | R2= 0.1625 | OK
[SMOKE TEST] Meta-modelo (Ridge) | filas= 20 | NaN=0 | Inf=0 | R2= 0.0312 | OK
[SMOKE TEST] Meta-modelo (Lasso) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1352 | OK
[SMOKE TEST] Meta-modelo (ElasticNet) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1997 | OK
[SMOKE TEST] Meta-modelo (Linear) | filas= 20 | NaN=0 | Inf=0 | R2=-0.5930 | OK
[SMOKE TEST] Meta-modelo (RandomForest) | filas= 20 | NaN=0 | Inf=0 | R2= 0.0659 | OK

--- oomy_asv_richness_z (holdout, 20 filas) ---
[SMOKE TEST] Ridge | filas= 20 | NaN=0 | Inf=0 | R2= 0.1394 | OK
[SMOKE TEST] RF single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.2743 | OK
[SMOKE TEST] XGBoost single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.2432 | OK
[SMOKE TEST] RF multiasalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.3024 | OK
[SMOKE TEST] XGBoost multiasalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.2506 | OK
[SMOKE TEST] RegressorChain | filas= 20 | NaN=0 | Inf=0 | R2= 0.2802 | OK
[SMOKE TEST] MLP multiasalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.2264 | OK
[SMOKE TEST] MLP custom loss | filas= 20 | NaN=0 | Inf=0 | R2= 0.1398 | OK
[SMOKE TEST] Meta-modelo (Ridge) | filas= 20 | NaN=0 | Inf=0 | R2= 0.2587 | OK
[SMOKE TEST] Meta-modelo (Lasso) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1086 | OK
[SMOKE TEST] Meta-modelo (ElasticNet) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1647 | OK
[SMOKE TEST] Meta-modelo (Linear) | filas= 20 | NaN=0 | Inf=0 | R2= 0.2334 | OK
[SMOKE TEST] Meta-modelo (RandomForest) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1872 | OK

--- cerc_asv_richness_z (holdout, 20 filas) ---
[SMOKE TEST] Ridge | filas= 20 | NaN=0 | Inf=0 | R2= 0.2057 | OK
[SMOKE TEST] RF single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.3594 | OK
[SMOKE TEST] XGBoost single-target | filas= 20 | NaN=0 | Inf=0 | R2= 0.3082 | OK
[SMOKE TEST] RF multiasalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.2667 | OK
[SMOKE TEST] XGBoost multiasalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.4049 | OK
[SMOKE TEST] RegressorChain | filas= 20 | NaN=0 | Inf=0 | R2= 0.3455 | OK
[SMOKE TEST] MLP multiasalida | filas= 20 | NaN=0 | Inf=0 | R2= 0.1363 | OK
[SMOKE TEST] MLP custom loss | filas= 20 | NaN=0 | Inf=0 | R2=-0.1239 | OK
[SMOKE TEST] Meta-modelo (Ridge) | filas= 20 | NaN=0 | Inf=0 | R2= 0.3590 | OK
[SMOKE TEST] Meta-modelo (Lasso) | filas= 20 | NaN=0 | Inf=0 | R2= 0.1213 | OK
[SMOKE TEST] Meta-modelo (ElasticNet) | filas= 20 | NaN=0 | Inf=0 | R2= 0.2181 | OK
[SMOKE TEST] Meta-modelo (Linear) | filas= 20 | NaN=0 | Inf=0 | R2= 0.0939 | OK
[SMOKE TEST] Meta-modelo (RandomForest) | filas= 20 | NaN=0 | Inf=0 | R2= 0.4917 | OK
```

8.- Comparativa: modelos individuales vs. ensamblado por media vs. meta-modelo

Todas las metricas de esta tabla se calculan sobre el mismo holdout, para que la comparacion entre modelos base, ensamblado simple y meta-modelo sea justa.

```
In [8]: rows = []
for target in TARGETS_TO_TEST:
    if target not in meta_models:
        continue
    y_true_holdout = y_eval[target].values[idx_holdout]
    for label, preds in holdout_predictions[target].items():
        rmse = mean_squared_error(y_true_holdout, preds) ** 0.5
        rows.append({
            "target": target,
            "modelo": label,
            "R2": r2_score(y_true_holdout, preds),
            "RMSE": rmse,
            "MAE": mean_absolute_error(y_true_holdout, preds),
            "tipo": "meta-modelo" if label.startswith("Meta-modelo (") else ("ensamblado media" if label == "Ensamblado (media)" else "ind")
        })

if not rows:
    print("[AVISO] No hay predicciones de holdout disponibles todavia. "
          "Revisa que los modelos base se hayan cargado (seccion 3), que el smoke test "
          "haya pasado (seccion 4) y que los meta-modelos se hayan entrenado (seccion 6).")
    results_df = pd.DataFrame(columns=["target", "modelo", "R2", "RMSE", "MAE", "tipo"])
else:
    results_df = pd.DataFrame(rows).sort_values(["target", "R2"], ascending=[True, False]).reset_index(drop=True)

results_df
```

Out[8]:

	target	modelo	R2	RMSE	MAE	tipo
0	bac_asv_richness_z	Meta-modelo (ElasticNet)	0.026856	0.808248	0.594321	meta-modelo
1	bac_asv_richness_z	Meta-modelo (Lasso)	0.018270	0.811806	0.617058	meta-modelo
2	bac_asv_richness_z	Meta-modelo (Ridge)	-0.016433	0.826030	0.592349	meta-modelo
3	bac_asv_richness_z	XGBoost multisalida	-0.089010	0.855012	0.627395	individual
4	bac_asv_richness_z	XGBoost single-target	-0.090581	0.855628	0.626837	individual
...	...	...	...	...	...	...
289	orib_species_richness_z	Meta-modelo (Linear)	-0.295042	1.020244	0.726350	meta-modelo
290	orib_species_richness_z	Meta-modelo (Lasso)	-0.315931	1.028440	0.734192	meta-modelo
291	orib_species_richness_z	Meta-modelo (ElasticNet)	-0.358041	1.044765	0.748035	meta-modelo
292	orib_species_richness_z	Meta-modelo (Ridge)	-0.436228	1.074420	0.769499	meta-modelo
293	orib_species_richness_z	Meta-modelo (RandomForest)	-0.590671	1.130714	0.867258	meta-modelo

294 rows x 6 columns

8.1.- Resumen agregado por target

Con muchos targets a la vez, `results_df` tiene demasiadas filas para leerla a ojo. Esta tabla se queda con una fila por target: el mejor modelo individual, el mejor meta-modelo (o ensamblado por media), cual de los dos gana, y si el mejor R2 de ese target es positivo (es decir, si hay alguna señal predictiva real) o no.

R2 <= 0 significa que ni el mejor modelo hace mejor que predecir siempre la media -- en esos targets el problema no es que meta-modelo usar, sino que los modelos base no tienen señal útil que aprender a combinar. En targets sin señal, además, conviene fijarse en si los meta-modelos quedan claramente peor que el mejor individual (mas sobreajuste al meta-train cuanto menos señal real hay para aprender).

```
In [9]: if results_df.empty:
    print("[AVISO] results_df esta vacio. Ejecuta primero las secciones 3-8.")
    summary_df = pd.DataFrame(columns=[
        "target", "mejor_individual", "R2_mejor_individual",
        "mejor_no_individual", "R2_mejor_no_individual", "gana_no_individual", "mejor_R2_global",
    ])
else:
    summary_rows = []
    for target in results_df["target"].unique():
        sub = results_df[results_df["target"] == target]

        individuales = sub[sub["tipo"] == "individual"].sort_values("R2", ascending=False)
        no_individuales = sub[sub["tipo"] != "individual"].sort_values("R2", ascending=False)

        mejor_individual = individuales.iloc[0] if not individuales.empty else None
        mejor_no_individual = no_individuales.iloc[0] if not no_individuales.empty else None

        r2_individual = mejor_individual["R2"] if mejor_individual is not None else float("-inf")
        r2_no_individual = mejor_no_individual["R2"] if mejor_no_individual is not None else float("-inf")

        summary_rows.append({
            "target": target,
            "mejor_individual": mejor_individual["modelo"] if mejor_individual is not None else None,
            "R2_mejor_individual": r2_individual,
            "mejor_no_individual": mejor_no_individual["modelo"] if mejor_no_individual is not None else None,
            "R2_mejor_no_individual": r2_no_individual,
            "gana_no_individual": bool(r2_no_individual > r2_individual),
            "mejor_R2_global": max(r2_individual, r2_no_individual),
        })

    summary_df = pd.DataFrame(summary_rows).sort_values("mejor_R2_global", ascending=False).reset_index(drop=True)

    n_targets = len(summary_df)
    n_gana_no_individual = int(summary_df["gana_no_individual"].sum())
    n_r2_positivo = int((summary_df["mejor_R2_global"] > 0).sum())

    print(f"Targets evaluados: {n_targets}")
    print(f"Targets donde algun meta-modelo/ensamblado supera al mejor individual: "
          f"{n_gana_no_individual}/{n_targets} ({n_gana_no_individual / n_targets:.0%})")
    print(f"Targets con señal predictiva real (mejor R2 > 0): "
          f"{n_r2_positivo}/{n_targets} ({n_r2_positivo / n_targets:.0%})")
    print(f"Targets sin señal predictiva (mejor R2 ≤ 0, ningun modelo le gana a la media): "
          f"{n_targets - n_r2_positivo}")

summary_df
```

Targets evaluados: 21

Targets donde algun meta-modelo/ensamblado supera al mejor individual: 9/21 (43%)

Targets con señal predictiva real (mejor R2 > 0): 18/21 (86%)

Targets sin señal predictiva (mejor R2 ≤ 0, ningun modelo le gana a la media): 3

	target	mejor_individual	R2_mejor_individual	mejor_no_individual	R2_mejor_no_individual	gana_no_individual	mejor_R2_global
0	coll_species_richness_z	RF multisalida	-0.069098	Meta-modelo (RandomForest)	0.523332	True	0.523332
1	earthworm_richness_z	XGBoost multisalida	0.508708	Meta-modelo (Ridge)	0.522522	True	0.522522
2	macro_order_richness_z	XGBoost multisalida	0.509020	Ensamblado (media)	0.397477	False	0.509020
3	cerc_asv_richness_z	XGBoost multisalida	0.404936	Meta-modelo (RandomForest)	0.491682	True	0.491682
4	coll_shannon_z	RF multisalida	-0.058985	Meta-modelo (Linear)	0.407715	True	0.407715
5	macro_shannon_z	RegressorChain	0.372242	Ensamblado (media)	0.297913	False	0.372242
6	earthworm_shannon_z	RegressorChain	0.366510	Meta-modelo (ElasticNet)	0.327297	False	0.366510
7	oomy_asv_richness_z	RF multisalida	0.302448	Meta-modelo (Ridge)	0.258726	False	0.302448
8	nematode_shannon_z	XGBoost multisalida	0.280802	Meta-modelo (Ridge)	0.259927	False	0.280802
9	euk_asv_richness_z	RF single-target	0.219539	Ensamblado (media)	0.208970	False	0.219539
10	cerc_shannon_z	RF multisalida	0.121626	Ensamblado (media)	0.065739	False	0.121626
11	oomy_shannon_z	MLP multisalida	0.109946	Ensamblado (media)	0.033054	False	0.109946
12	euk_shannon_z	RF multisalida	0.103819	Meta-modelo (ElasticNet)	0.072138	False	0.103819
13	meso_species_richness_z	RF single-target	0.053125	Ensamblado (media)	-0.002852	False	0.053125
14	bac_asv_richness_z	XGBoost multisalida	-0.089010	Meta-modelo (ElasticNet)	0.026856	True	0.026856
15	meso_shannon_z	RegressorChain	0.023491	Meta-modelo (Linear)	-0.114632	False	0.023491
16	orib_shannon_z	MLP custom loss	-0.001389	Meta-modelo (Lasso)	0.014629	True	0.014629
17	fun_shannon_z	Ridge	-0.045406	Meta-modelo (Linear)	0.006084	True	0.006084
18	fun_asv_richness_z	Ridge	-0.087334	Meta-modelo (Lasso)	-0.018913	True	-0.018913
19	bac_shannon_z	RegressorChain	-0.129290	Meta-modelo (ElasticNet)	-0.050019	True	-0.050019
20	orib_species_richness_z	RF multisalida	-0.054500	Ensamblado (media)	-0.080917	False	-0.054500

9.- Visualización

Barras de R2 por modelo y target sobre el holdout. Los meta-modelos y el ensamblado por media se resaltan con borde negro para distinguirlos de los modelos base.


```
In [10]: if results_df.empty:
    print("[AVISO] results_df esta vacio, no hay nada que graficar. Ejecuta primero las secciones 3-8.")
else:
    targets_present = [t for t in TARGETS_TO_TEST if t in results_df["target"].unique()]
    palette = sns.color_palette("Set2", n_colors=max(len(targets_present), 3))
    TARGET_COLORS = dict(zip(targets_present, palette))


    fig, axes = plt.subplots(len(targets_present), 1, figsize=(9, 3.4 * len(targets_present)), squeeze=False)


    for ax, target in zip(axes[:, 0], targets_present):
        sub = results_df[results_df["target"] == target].sort_values("R2", ascending=False)
        base_color = TARGET_COLORS[target]
        is_highlighted = sub["tipo"] != "individual"
        colors = [base_color if h else sns.light_palette(base_color, n_colors=3)[1] for h in is_highlighted]
        edgecolors = ["black" if h else "none" for h in is_highlighted]
        linewidths = [1.6 if h else 0 for h in is_highlighted]






        bars = ax.bar(sub["modelo"], sub["R2"], color=colors, edgecolor=edgecolors, linewidth=linewidths)
        for bar, r2 in zip(bars, sub["R2"]):
            ax.text(bar.get_x() + bar.get_width() / 2, bar.get_height() + 0.01, f"{r2:.3f}",
                    ha="center", fontsize=8.5, color="#333333")
        ax.set_title(f"R2 por modelo (holdout) - {target}", fontsize=11, fontweight="bold")
        ax.set_ylabel("R2")
        ax.tick_params(axis="x", rotation=25)
        ax.spines["top"].set_visible(False)
        ax.spines["right"].set_visible(False)

    fig.tight_layout()
    fig.savefig("output/r2_comparativa_con_modelos.png", dpi=300, bbox_inches="tight")
    plt.show()
```









10. Conclusiones

Al añadir cinco meta-modelos (Ridge, Lasso, ElasticNet, Linear y RandomForest) entrenados sobre las predicciones de los 8 modelos base, la frecuencia de victorias mejora respecto a la Prueba 4.1: algún meta-modelo o el ensamblado por media supera ahora al mejor individual en 9 de los 21 targets (43%, frente al 19% anterior), y el 86% de los targets muestran señal predictiva real (mejor $R^2 > 0$), frente al 71% de la prueba anterior. De los dos targets prioritarios, solo `earthworm_richness_z` se beneficia: el Meta-modelo (Ridge) alcanza $R^2=0.5225$ frente a 0.5087 del mejor individual (XGBoost multisalida), una mejora de +0.014. En `earthworm_shannon_z`, en cambio, ningún meta-modelo ni el ensamblado por media logra superar a RegressorChain ($R^2=0.3665$); el más cercano es el Meta-modelo ElasticNet, con 0.3273.

Dos de las mejoras observadas merecen, sin embargo, mirarse con escepticismo: en `coll_species_richness_z`, el Meta-modelo (RandomForest) pasa de $R^2=-0.069$ a 0.523, y en `coll_shannon_z`, el Meta-modelo (Linear) pasa de -0.059 a 0.408. Un salto tan grande en targets que originalmente no tenían ninguna señal predictiva, calibrado con solo 45 filas y evaluado sobre 20, encaja mejor con un sobreajuste del meta-modelo a esa partición concreta que con una mejora real y reproducible.

De hecho, hay un patrón que respalda esa sospecha: de las 9 veces que un candidato no-individual gana, los meta-modelos regularizados (Ridge, Lasso, ElasticNet) lo hacen 7 veces, y RandomForest, el más flexible y menos regularizado, solo 2, coincidiendo exactamente con los dos saltos sospechosos descritos arriba. Con tan pocos datos de calibración, el candidato menos regularizado es también el más propenso a memorizar el meta-train en vez de generalizar, mientras que los modelos lineales regularizados producen mejoras más pequeñas pero más creíbles. Tampoco existe un meta-modelo "ganador universal": Ridge, Lasso, ElasticNet y el ensamblado por media se reparten las victorias sin un patrón evidente según el tipo de target (diversidad vs. riqueza, o grupo taxonómico).

Nada de esto se ha contrastado todavía frente al `RANDOM_STATE`: la ejecución usa una única semilla para el `train_test_split`, y con un holdout de solo 20 filas, mejoras por debajo de $\sim 0.02-0.03$ de R^2 , como la de +0.014 en `earthworm_richness_z`, están dentro del margen de ruido esperable al cambiar de partición. Antes de decidir nada, convendría repetir el notebook con varias semillas, target a target y meta-modelo a meta-modelo, y, si en el futuro se dispone de más datos, sustituir el único split train/holdout por validación cruzada con predicciones out-of-fold, que reduciría justamente el riesgo de sobreajuste que sugieren los dos saltos de R^2 más grandes.

En conjunto: el stacking con meta-modelo mejora la tasa de victorias frente al ensamblado simple de la Prueba 4, y ofrece la única mejora creíble en un target prioritario (`earthworm_richness_z`, Ridge, +0.014). Pero es una mejora modesta, no validada frente al `RANDOM_STATE`, y varias de las victorias más llamativas (con RandomForest, en targets sin señal previa) tienen toda la pinta de ser artefactos de sobreajuste. Dado el coste de mantener y versionar cinco meta-modelos por target, no se recomienda llevar ningún meta-modelo a producción sin antes repetir el experimento con varias semillas y, si es posible, con validación cruzada.